

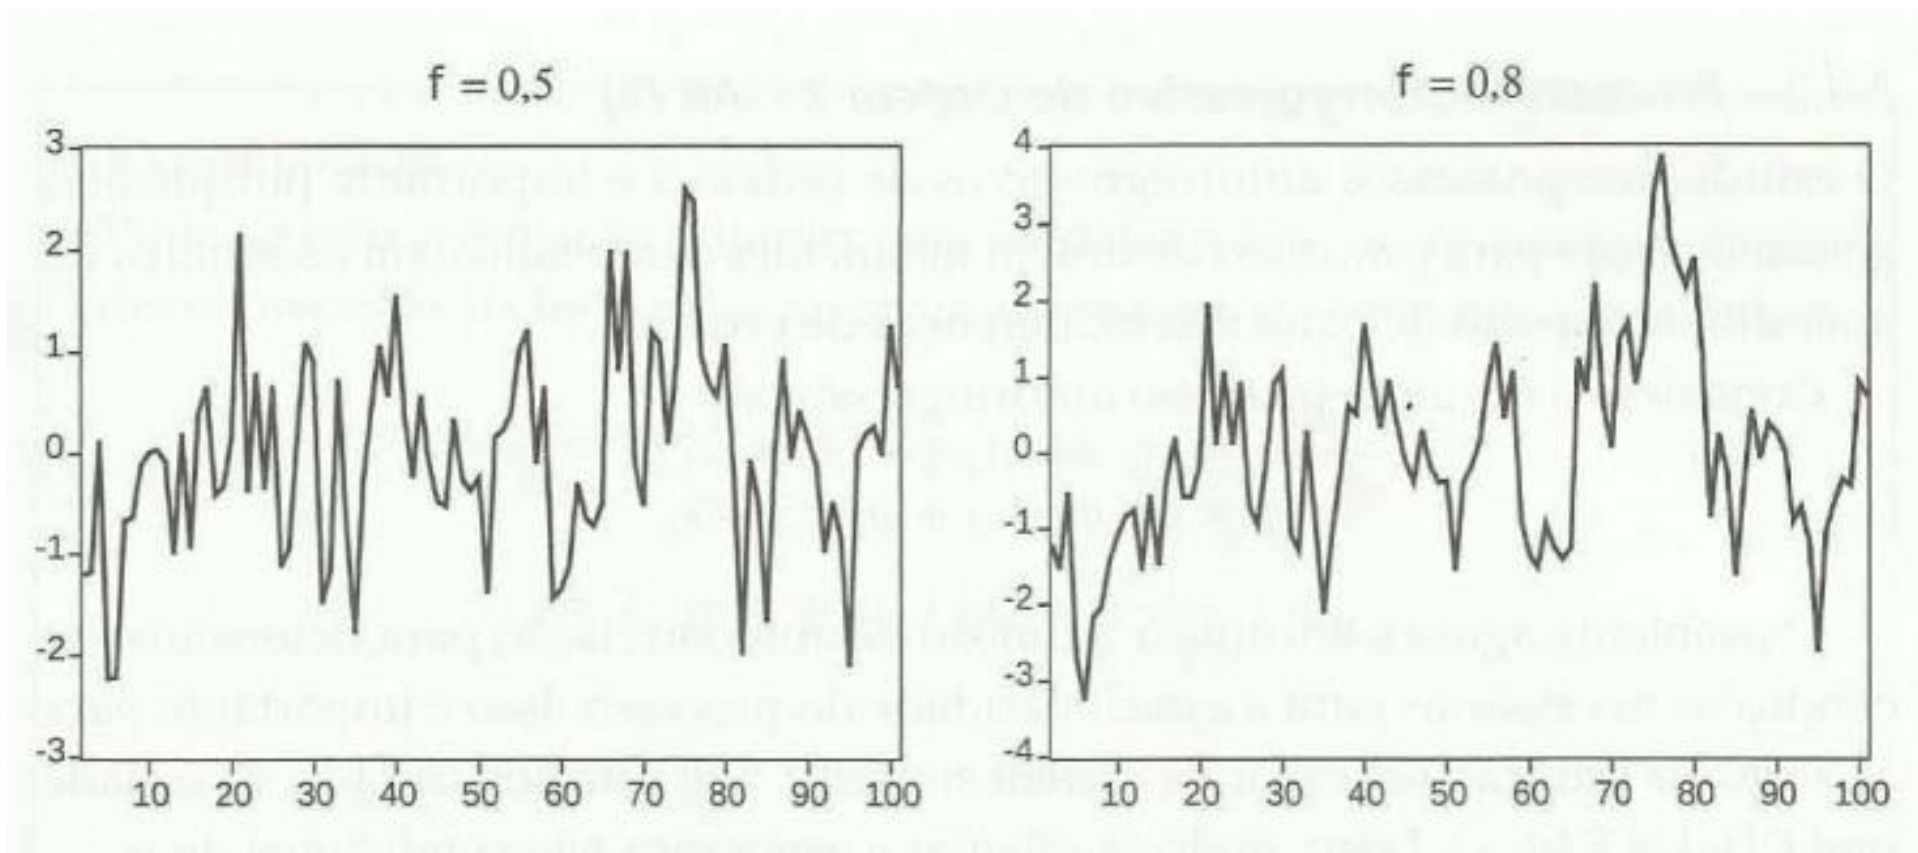
Modelo Autorregressivo de Ordem 1 AR(1)

Um processo autorregressivo de ordem 1 é definido como:

$$y_t = c + \phi y_{t-1} + \epsilon_t$$


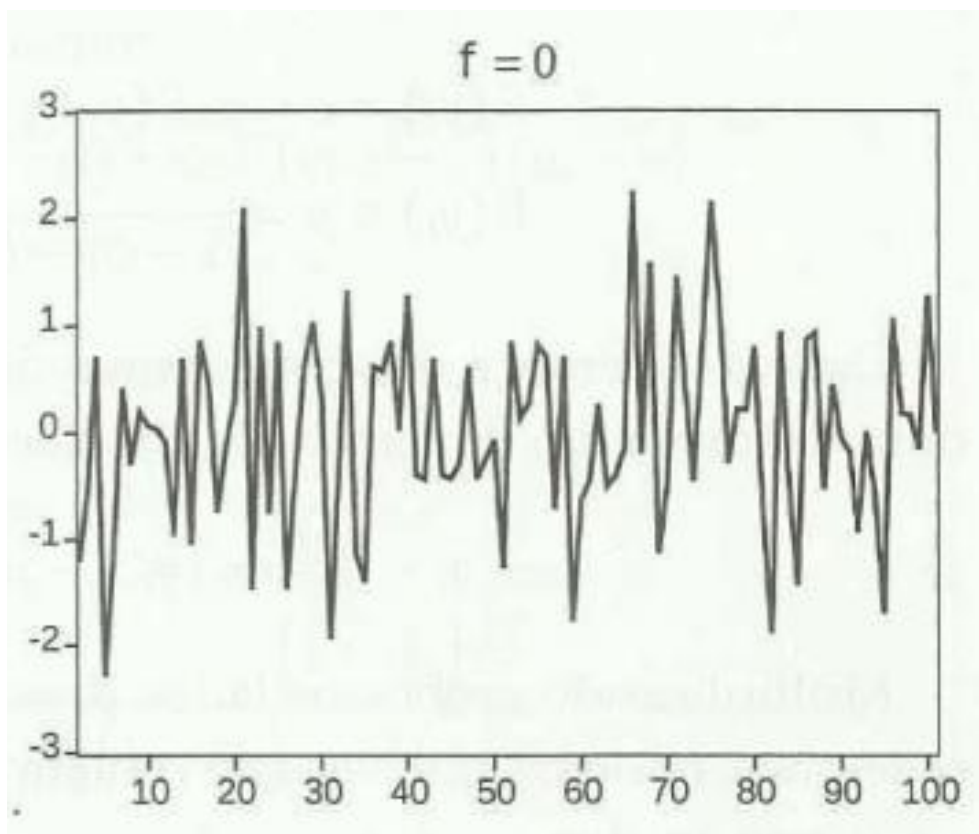
*Condição necessária: $\phi < 1$
 ϵ_t seja um ruído branco*

Comparando as duas figuras abaixo: o processo em que $\phi=0,8$ parece mais resistente a mudanças que um processo $\phi=0,5$.



Da mesma forma, o processo a esquerda parece ser mais volátil, embora ambos tenham sido gerados com mesmo valor para variância.

Essa volatilidade reflete sobre os valores da autocovariância. Quando $\phi=0$ é difícil definir um padrão para os dados, tratando-se de um ruído branco.



Modelo Autorregressivo de Ordem p AR(p)

De forma geral, o processo regressivo de ordem p é dado por:

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

Operador de Defasagem

Outra forma de escrever os processos autorregressivos é utilizando o operador de defasagens. Suas propriedades básicas:

$$1) Ly_t = y_{t-1}$$

$$2) Lc = c$$

$$3) L^2 y_t = L\{Ly_t\} = Ly_{t-1} = y_{t-2}$$

$$4) (1 - L)y_t = y_t - Ly_t = y_t - y_{t-1} = \Delta y_t$$

$$5) L(1 - L)y_t = (1 - L)Ly_t = (1 - L)y_{t-1} = \Delta y_{t-1}$$

Assumindo estacionaridade fraca, podemos definir a k-ésima ordem de autocovariância, γ , como:

$$\gamma_k = cov\{\mathbf{y}_t, \mathbf{y}_{t-k}\} = cov\{y_t, y_{t+k}\}$$

A autocovariância de um processo estocástico pode ser normalizada e apresentada como uma função de autocorrelação, ρ_k :

$$\rho_k = \frac{cov\{\mathbf{y}_t, \mathbf{y}_{t-k}\}}{V\{\mathbf{y}_t\}}$$

Função de Autocorrelação - FAC



A Função de Autocorrelação – FAC ou ACF do inglês - nos ajuda a caracterizar a influência de y_t ao longo do tempo.

Ela nos mostra o quão forte o valor observado hoje está correlacionado com os valores observados no passado.

Nos auxilia a identificar sazonalidades

Gera *insights* de como choques hoje afetarão os valores futuros da variável em questão.

Função de Autocorrelação - FAC



Função de Autocorrelação Parcial - FACP

A Função de Autocorrelação Parcial –FACP ou PACF, do inglês - nos dá **correlação entre a variável no instante t e uma de suas defasagens**, retirado os efeitos das outras defasagens.


Por exemplo o:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \epsilon_t$$


A FACP irá captar o efeito ϕ_1 direto de y_{t-1} sobre y_t sem considerar $\phi_2 y_{t-2}$ e o efeito ϕ_2 direto de y_{t-2} sobre y_t sem considerar $\phi_1 y_{t-1}$.

Função de Autocorrelação Parcial - FACP

AR(1) com $\theta=0.9$



AR(1) com $\theta=-0.9$



```
library(readxl)
library(urca)
```

```
IPCA <- read_excel("C:/Econometria/IPCA.xls", col_types = c("date","numeric"))
```

```
Inflacao <- ts(IPCA,start = 2008-01, frequency = 12)
Inflacao <- Inflacao[,-1]
```

```
view(Inflacao)
```

1	0.5196
2	0.1898
3	0.3132
4	0.5376
5	1.2286
6	0.9565
7	0.4505
8	0.3794
9	0.3794
10	0.4979
11	0.3880
12	0.1603
13	0.1615

```
TesteDF <- summary(ur.df(Inflacao, type="none", lags=0))
```

TesteDF

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression none

call:
lm(formula = z.diff ~ z.lag.1 - 1)

Residuals:
    Min       1Q   Median       3Q      Max
-0.7824 -0.1219  0.0827  0.2890  1.3882

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1 -0.20984      0.05443   -3.856 0.000184 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.3461 on 125 degrees of freedom
Multiple R-squared:  0.1063,    Adjusted R-squared:  0.09914
F-statistic: 14.87 on 1 and 125 DF,  p-value: 0.0001837

value of test-statistic is: -3.8556

Critical values for test statistics:
      1pct   5pct 10pct
tau1 -2.58 -1.95 -1.62
```


Função de Autocorrelação Parcial - FAC

```
acf(IPCA$IPCA, main="Inflacao Mensal")
```



Função de Autocorrelação Parcial - FACP

```
pacf(IPCA$IPCA, main="Inflacao Mensal")
```



```
AR1 <- arima(Inflacao, order = c(1,0,0))
```

```
AR1
```

```
call:
```

```
arima(x = Inflacao, order = c(1, 0, 0))
```

```
Coefficients:
```

	ar1	intercept
	0.4648	0.4404
s.e.	0.0781	0.0513

```
sigma^2 estimated as 0.09696: log likelihood = -32.15, aic = 70.3
```

$$y_t = 0,4404 + 0,4648_1 y_{t-1} + \epsilon_t$$

$(0,0513) \quad (0,0781)$

```
AR2 <- arima(Inflacao, order=c(2,0,0))  
AR2
```

```
call:  
arima(x = Inflacao, order = c(2, 0, 0))
```

```
Coefficients:
```

	ar1	ar2	intercept
	0.4342	0.0636	0.4405
s.e.	0.0891	0.0899	0.0544

```
sigma^2 estimated as 0.09657: log likelihood = -31.9, aic = 71.8
```

$$y_t = 0,4405 + 0,4342_1 y_{t-1} + 0,0636_1 y_{t-1} + \epsilon_t$$

(0,0544)	(0,0891)	(0,0899)
----------	----------	----------